

GUÍA DE COMPRENSIÓN PARA EL EQUIPO

“Entendiendo SmartInbox RIWI: Doble Caché, Cascada Gratuita y Máxima Velocidad Explicada con Plastilina”

1. ¿QUÉ ES EL DOBLE MOTOR DE CACHÉ?

Imagina que un cliente envía el mismo PDF de 20 páginas dos veces por error. En un sistema novato, la máquina vuelve a hacer OCR y gastar 10 segundos inútilmente. En SmartInbox RIWI:

- **Motor 1 (Huella Digital Criptográfica):** Calcula la huella digital única (SHA-256) del archivo en 0.001 segundos.
- **Motor 2 (Caché en Memoria):** Si la huella ya existe en la base de datos, el sistema devuelve el resultado guardado en 0.002 segundos, sin gastar ni un ciclo de procesador.

2. ¿CÓMO FUNCIONA LA CASCADA MULTI-PROVEEDOR?

Para entender quejas de clientes sin gastar dinero y sin que el sistema se caiga jamás, usamos una cascada de 3 niveles:

- **Nivel 1 (Groq Cloud API):** Le pregunta a Groq Cloud (gratis), que responde en solo 0.2 segundos gracias a sus chips ultrarrápidos.
- **Nivel 2 (Google Gemini Flash):** Si Groq agota su cuota por minuto o se satura, pasa automáticamente a Google AI Studio (Gemini Flash gratis).
- **Nivel 3 (Salvavidas Local Offline):** Si no hay internet o se cortan las conexiones externas, un modelo local pequeño (Llama 3.2 3B en Ollama) resuelve la tarea en la máquina.

3. GLOSARIO DE TÉRMINOS PARA ENTENDER LA TECNOLOGÍA

- **PaddleOCR (PP-OCRv4):** Motor de OCR de última generación basado en redes neuronales profundas (DBNet). Es hasta 3 veces más rápido que Tesseract y lee texto borroso donde otros fallan.
- **YOLOv8-Nano:** Modelo de visión ultraligero (pesa 6 MB) que detecta objetos como árboles, personas o vehículos en 15 milisegundos en cualquier CPU humilde.
- **Moondream2:** Modelo de visión y lenguaje diminuto (1.6B parámetros) que corre en computadores locales sin tarjeta gráfica y responde preguntas visuales en menos de 1 segundo.
- **Multiprocessing (ProcessPoolExecutor):** Técnica de Python para usar todos los núcleos del procesador al mismo tiempo, dividiendo el trabajo de las 20 páginas en paralelo.
- **RapidFuzz:** Algoritmo que encuentra palabras clave aunque el escaneo borroso haya cambiado una letra (ej. encuentra 'árbol' aunque diga 'arbo1').

4. EL ROL DE CADA UNO EN EL EQUIPO

- **Daniel David Martinez Gonzalez:** Arquitectura del sistema, concurrencia multiproceso para procesar en paralelo y seguridad de datos.
- **Breyner De Jesus Manga Arias:** Pipeline de filtros OpenCV para escaneos borrosos, parser XML DIAN y diseño de la base de datos de auditoría.
- **Joseph Romero:** Configuración de PaddleOCR ONNX, integración de YOLOv8/Moondream2 y consola web para excepciones.