

PROPUESTA TÉCNICA Y COMERCIAL DEFINITIVA — LISTA PARA PRODUCCIÓN

AUTOMATIZACIÓN INTELIGENTE DEL BUZÓN CORPORATIVO DE RIWI

“SmartInbox RIWI: Arquitectura de Ultra-Rendimiento (\$0 USD), Doble Motor de Caché, Cascada Multi-Proveedor y Procesamiento de Documentos Degradados”

Cliente:	RIWI Barranquilla
Canal Objetivo:	info@riwi.io (Punto Único de Entrada Inviolable)
Presupuesto de Licenciamiento:	100% Gratuito y Open Source (\$0.00 USD)
Fecha de Emisión:	Versión Definitiva para Producción — Septiembre 2026

EQUIPO CONSULTOR PROPONENTE

Daniel David Martinez Gonzalez	<i>Especialista en Arquitectura Open Source, Concurrencia e Integración</i>
Breyner De Jesus Manga Arias	<i>Especialista en Datos, Preprocesamiento OpenCV & Estándares DIAN</i>
Joseph Romero	<i>Especialista en Visión Computacional, Inferencia VLM & Modelos de Lenguaje</i>

1. RESUMEN EJECUTIVO

La presente propuesta técnica y comercial establece el diseño arquitectural definitivo de SmartInbox RIWI, una solución concebida para operar en un entorno de producción real, resolviendo de forma integral el flujo de comunicaciones del buzón info@riwi.io con máxima velocidad, costo cero de licenciamiento y una estricta minimización del uso de Inteligencia Artificial.

Entendiendo que en el mundo productivo la Inteligencia Artificial debe usarse como una herramienta quirúrgica y no como un fin en sí misma, la arquitectura asigna el 75% de la carga de trabajo a algoritmos deterministas de alta velocidad (C++, álgebra lineal y reglas de negocio), reservando la IA únicamente para el 25% donde se requiere percepción humana (OCR neuronal sobre texto borroso, detección visual de objetos y comprensión de lenguaje libre).

Pilares de la Solución de Producción

- **Doble Motor de Caché Criptográfico:** Antes de invocar cualquier modelo u OCR, el sistema calcula el hash SHA-256 del documento. Si el archivo ya fue procesado antes, retorna los metadatos en 0.002 segundos, ahorrando el 100% del procesamiento.
- **Cascada Multi-Proveedor Gratuita:** Para el texto semántico (PQRS), el sistema consulta Tier 1: Groq Cloud API (LPU a 600 tok/s en 0.2s); si la cuota se agota, conmuta a Tier 2: Google AI Studio (Gemini 2.0 Flash Free); y si no hay internet, conmuta a Tier 3: Ollama local (Llama 3.2 3B). Cero caídas y cero costos.
- **Restauración de Documentos Degradados (Caso Real):** Pipeline de visión matemática con OpenCV (filtro Unsharp Masking vectorizado y binarización Sauvola) para rescatar texto de escaneos borrosos, arrugados o de baja calidad.
- **OCR de Alto Rendimiento en 20 Páginas:** Motor neuronal en C++ (PP-OCRv4 con ONNX Runtime) que supera en 3x la velocidad de Tesseract y lee trazos deformados en paralelo.
- **Visión Ligera y Renombrado Estandarizado:** Detección en 15 milisegundos mediante YOLOv8-Nano para responder si en una foto hay un árbol, firma o sello, complementado con RapidFuzz para palabras clave y renombrado automático de archivos.

2. ANÁLISIS DEL PROBLEMA Y CASOS EXTREMOS REALES

En la operación cotidiana de RIWI Barranquilla, el buzón info@riwi.io recibe cientos de correos heterogéneos. En el mundo real, los documentos no llegan en condiciones ideales:

- **1. Documentos Multipágina Pesados (20+ Páginas):** Expedientes escaneados a 600 DPI que generan archivos de 80 MB. Un OCR secuencial tradicional tardaría más de 90 segundos; la arquitectura multiproceso lo resuelve en 3 a 5 segundos.
- **2. Imágenes Borrosas y Desenfoque:** Escaneos torcidos, fotos tomadas con celular con iluminación deficiente o documentos arrugados que hacen fallar a los OCRs estándar.
- **3. Contenido Visual No Estructurado:** Mezcla de hojas de texto contractual con fotos adjuntas (inspecciones de compras, fotos de bienes o certificados) donde se requiere verificar si hay un árbol, una firma o un sello.
- **4. Heterogeneidad Fiscal:** Proveedores que envían facturas en contenedores .zip con XML legítimo de la DIAN, pero también proveedores que adjuntan facturas físicas escaneadas.

La Restricción Inviolable: info@riwi.io como Canal Único

Con más de dos millones de clientes y cientos de proveedores registrados, info@riwi.io es un canal permanente. La solución opera como una capa de servicio invisible sin obligar a los clientes a migrar a nuevos correos ni trasladar la carga de trabajo al personal interno.

3. SOLUCIÓN PROPUESTA Y ESPECIALIZACIÓN DE PROCESOS




Figura 1: Especialización técnica y análisis multimodal open source en SmartInbox RIWI.

3.1. Facturación Electrónica DIAN (Cuentas por Pagar)

Tratamiento determinista con validez jurídica y cero error contable:

- **Validación UBL 2.1:** Apenas llega un adjunto .zip, se descomprime en memoria protegida y se parsea el XML UBL 2.1 (AttachedDocument / Invoice) con lxml nativo. Se extraen matemáticamente CUFE, NIT, fechas, subtotal, IVA y total a pagar.
- **Bloqueo de Duplicados:** Verificación instantánea en PostgreSQL/SQLite para impedir el pago de facturas repetidas y conciliación con la Orden de Compra citada.
- **Enrutamiento:** Radicación directa en el ERP de Cuentas por Pagar sin requerir inferencia de modelos pesados.

3.2. Órdenes de Compra y PDFs Complejos (Servicios Internos)

Pipeline especializado en documentos con imágenes borrosas y texto degradado de 20 páginas:

- **Triage de Capa Inteligente:** PyMuPDF (fitz) escanea las 20 páginas. Si la página tiene texto vectorial nativo, lo extrae en 0.005 segundos. Si es escaneo puro, la envía al pipeline visual.
- **Restauración OpenCV:** La imagen pasa por OpenCV: eliminación de ruido, corrección de inclinación (Deskewing) y filtro Unsharp Masking para devolver nitidez a las letras.
- **OCR Neuronal Ultrarrápido:** PaddleOCR con motor ONNX procesa los bloques de texto en paralelo aprovechando los núcleos del CPU.
- **Detección Visual Dual:** YOLOv8-Nano analiza las fotos extraídas en 15 milisegundos para confirmar la presencia de elementos visuales (ej. árbol sí/no, sellos o firmas). Si se requiere una pregunta semántica compleja, interviene Moondream2 (1.6B) vía Ollama en menos de 1 segundo.
- **Búsqueda Difusa:** RapidFuzz localiza palabras clave incluso si el texto borroso provocó lecturas imperfectas (ej. arbo1 -> árbol).
- **Renombrado y Archivo:** El archivo se renombra automáticamente como {FECHA}_{TIPO}_{ARBOL_SI/NO}_{ID}.pdf y se mueve a la carpeta de Servicios Internos.

3.3. Proceso de PQRS (Servicio al Cliente - SAC)

- **NLU Semántico en Cascada:** Se envía el texto limpio a Groq Cloud API (Llama 3.3 70B) que interpreta el tono y la intención en 0.2 segundos, con fallback a Gemini Flash y Ollama local.
- **Priorización y Ticket:** Asignación de nivel de severidad (Alta/Media/Baja) y creación de ticket automático en SAC con acuse de recibo al usuario.

4. ARQUITECTURA DE LA SOLUCIÓN




Figura 2: Arquitectura Empresarial de Producción con Doble Caché y Cascada Multi-Proveedor.

Componentes de la Arquitectura de Producción

- **1. Capa de Ingesta:** Conector reactivo por webhook de correo mediante API abierta.
- **2. Doble Motor de Caché y Cola:** Hash SHA-256 del archivo para bypass instantáneo de documentos ya procesados + cola en memoria (asyncio.Queue / Redis local).
- **3. Pipeline de Restauración Visual:** OpenCV (cv2) con kernels optimizados de nitidez, contraste CLAHE y binarización adaptativa Sauvola.
- **4. Motores de Inferencia Local:** PaddleOCR (PP-OCRv4 ONNX) en 4 núcleos + YOLOv8-Nano local en 15 ms para detección de objetos.
- **5. Cascada Multi-Proveedor:** Tier 1: Groq Cloud API (0.2s) -> Tier 2: Google Gemini Flash Free (Visión) -> Tier 3: Ollama Local (Offline).

- **6. Capa Human-in-the-Loop:** Consola web local en FastAPI/React para que un analista apruebe o corrija casos dudosos en 2 clics.
- **7. Archivo y Persistencia:** Almacenamiento local con renombrado estandarizado y base de datos relacional para auditoría.

5. AUTOMATIZACIÓN TRADICIONAL VS. INTELIGENCIA ARTIFICIAL

La solución aplica la tecnología justa para cada necesidad, evitando el desperdicio computacional y garantizando precisión:

Actividad	Mecanismo Seleccionado	Justificación Técnica de Rendimiento
Validación fiscal .ZIP/XML	Parser lxml nativo (0% IA)	100% determinista. Los LLMs no son calculadoras; lxml garantiza cero errores de cálculo y cero costo.
Enfoque de escaneos borrosos	Filtros OpenCV (C++)	Convolución matemática instantánea para restaurar bordes y limpiar sombras en milisegundos.
OCR de 20 páginas	PaddleOCR PP-OCRv4 (ONNX)	Red neuronal profunda DBNet. Supera en 3x a Tesseract en velocidad y rescata texto severamente borroso.
Detección de objetos ('árbol')	YOLOv8-Nano (Ultralytics)	15 milisegundos en CPU. Usar un LLM gigante para buscar un árbol es ineficiente; YOLO lo resuelve al instante.
Comprensión de quejas PQRS	Cascada: Groq -> Gemini -> Ollama	Velocidad de 0.2s en la nube gratuita con salvavidas offline local por si falla internet.

6. FLUJO DE PROCESAMIENTO END-TO-END




Figura 3: Flujo de procesamiento end-to-end con doble caché, cascada y renombrado.

El ciclo de vida del documento consta de 7 etapas consecutivas:

- **1. Ingesta & Doble Caché:** Captura de correo, descarga de adjuntos y verificación del hash SHA-256. Si ya existe en base de datos, retorna en 0.002s.
- **2. Triage y Restauración:** Triage de capas en PyMuPDF: las páginas digitales se extraen al instante; las páginas borrosas pasan a restauración OpenCV.
- **3. Compuerta Rápida DIAN:** Si hay contenedor .zip con XML DIAN, pasa a validación inmediata lxml.
- **4. Extracción Híbrida:** PaddleOCR extrae el texto en paralelo. YOLOv8-Nano inspecciona imágenes para confirmar presencia de objetos (árbol sí/no).
- **5. Validación de Negocio:** Validación cruzada con RapidFuzz y cálculo de Score de Confianza Compuesto (C).
- **6. Renombrado y Enrutamiento:** Si $C \geq 0.90$, el archivo se renombra como {FECHA}_{TIPO}_{ARBOL_SI/NO}_{ID}.pdf y se mueve a la carpeta departamental. Si $C < 0.90$, pasa a Human-in-the-Loop.
- **7. Auditoría:** Registro inmutable en base de datos local y emisión de métricas diarias.

7. MANEJO DE EXCEPCIONES (HUMAN-IN-THE-LOOP)

La intervención humana solo ocurre ante verdadera incertidumbre:

- **Criterio de Disparo:** Se dispara cuando el índice de confianza es inferior al 90% ($C < 0.90$) o cuando una imagen está tan dañada que no es posible extraer los campos obligatorios.
- **Resolución en 2 Clics:** El analista visualiza una pantalla dividida con el PDF a la izquierda y el formulario prellenado a la derecha, con el campo dudoso resaltado.
- **Trazabilidad:** La corrección queda guardada como dato de entrenamiento para retroalimentación continua del sistema.

8. TRAZABILIDAD Y AUDITORÍA EMPRESARIAL

El sistema garantiza el registro inmutable de cada transacción:

- **Identificación Inmutable:** Trace-ID único, fecha y hora con precisión de milisegundos, remitente y hash SHA-256.
- **Metadatos Almacenados:** Resultado del OCR, score de certeza, etiquetas visuales detectadas (ej. árbol: SÍ) y nuevo nombre del archivo.
- **Seguridad:** Cifrado local AES-256, políticas de acceso RBAC y estricto apego a la Ley 1581 de Habeas Data.

9. REPORTES E INDICADORES DE GESTIÓN

Generación diaria automática a las 07:00 y 18:00 hrs:

- **Tasa de Procesamiento Directo (STP):** $> 90\%$ de expedientes y correos resueltos sin intervención de personal.
- **Latencia de Procesamiento:** De 3 a 5 segundos totales para procesar un PDF escaneado de 20 páginas (vs. más de 60 segundos con motores tradicionales).
- **Resumen Financiero:** Monto total de facturas DIAN UBL procesadas y duplicados bloqueados.

10. PROPUESTA TECNOLÓGICA Y JUSTIFICACIÓN DEL STACK

- **Manipulación de PDFs de 20 Páginas:** PyMuPDF (fitz) para extracción de texto vectorial y capas; pdf2image para renderizado a 300 DPI.
- **Restauración de Imágenes Borrosas:** OpenCV (cv2) con kernels optimizados de nitidez, contraste CLAHE y binarización adaptativa Sauvola.
- **Motor de OCR:** PaddleOCR (PP-OCRv4 ONNX) ejecutado localmente con aceleración multi-núcleo.
- **Visión Multimodal:** YOLOv8-Nano (15 ms) para detección instantánea de objetos + Moondream2 (1.6B) vía Ollama para preguntas abiertas.
- **NLU Semántico:** Cascada: Groq Cloud API (Tier 1) -> Google Gemini Flash (Tier 2) -> Ollama local (Tier 3).
- **Búsqueda de Palabras Clave:** RapidFuzz para búsqueda difusa con tolerancia a errores de escaneo.
- **Backend y Persistencia:** Python 3.11 + FastAPI + PostgreSQL / SQLite local con caché SHA-256.

11. ROADMAP DE IMPLEMENTACIÓN POR FASES

Cronograma de 14 semanas para el equipo de 3 especialistas:

- **Fase 1 (Semanas 1-4): Cimientos, Doble Caché & Facturación DIAN:** Despliegue de ingesta, parser .zip/XML DIAN y estructura de base de datos local con caché SHA-256.

- **Fase 2 (Semanas 5-8): PDFs Complejos, OCR & Análisis Visual:** Pipeline de OpenCV para escaneos borrosos, PaddleOCR ONNX, YOLOv8-Nano en Ollama y lógica de renombrado.
- **Fase 3 (Semanas 9-11): Trazabilidad, Métricas & Pruebas Reales:** Auditoría con Trace-ID, tableros de métricas y pruebas con PDFs reales de 20 páginas suministrados por el TL.
- **Fase 4 (Semanas 12-14): Despliegue Productivo & Cierre:** Despliegue gradual (Canary Rollout), capacitación y entrega formal.

Asignación de Roles del Equipo

- **Daniel David Martinez Gonzalez (Arquitectura Open Source, Concurrencia e Integración):** Arquitectura de servicios locales, concurrencia multiproceso e integración con sistemas destino.
- **Breyner De Jesus Manga Arias (Datos, Preprocesamiento OpenCV & DIAN):** Pipeline de OpenCV para escaneos borrosos, parser XML DIAN y diseño de base de datos de auditoría.
- **Joseph Romero (Visión Computacional, Inferencia VLM & Modelos de Lenguaje):** Configuración de PaddleOCR ONNX, integración de YOLOv8/Moondream2 y consola Human-in-the-Loop.

12. CONCLUSIÓN Y VALOR ESTRATÉGICO

SmartInbox RIWI demuestra que no se requieren suscripciones costosas en la nube para construir la solución documental más rápida del mercado. Al integrar la velocidad de PaddleOCR con la potencia de OpenCV y la agilidad de YOLOv8-Nano, el aplicativo procesa expedientes complejos de 20 páginas en segundos, identifica objetos visuales con precisión milimétrica y garantiza el orden y la trazabilidad operativa bajo un costo de licenciamiento de cero dólares.